

ZÁPADOČESKÁ
UNIVERZITA
V PLZNI

Semestrální práce na předmět TKS

Detekce evokovaných potenciálů diskrétní
waveletovou transformací

Jméno a příjmení: *Petr Soukal*

Osobní číslo: *A08N0050P*

E-mail: *psoukal@students.cz*

1 Zadání

Využití waveletové transformace při detekci ERP:

- Nejdříve prostudujte princip metody WT z dodaných podkladů.
- Vyberte vhodný způsob implementace metody WT.
- Implementujte metodu v jazyce Java, jako lehkou komponentu (metoda bude pracovat pouze s primitivními datovými typy a poli)
- Bude kladen důraz na přehlednost a kvalitu kódu, dále bude požadována podrobná dokumentace v JavaDoc.
- Implementace metody bude začleněna do vznikající knihovny.
- Otestujte možnosti metody při detekci ERP při využití různých druhů waveletů.
- Výsledky shrňte do cca desetistránkové závěrečné zprávy.

2 EEG/ERP a Waveletová Transformace

Co je to EEG?

EEG (elektroencefalografie) je vyšetření registrující aktuální elektrickou aktivitu mozku povrchovými elektrodami umístěnými na povrchu lebky. Výsledný záznam je označován jako elektroencefalogram. Dnes patří EEG k nejpoužívanějším diagnostickým metodám v neurologii. Slouží k odhalení změn v elektrické aktivitě mozku při podezření na jeho neobvyklou činnost. Indikuje se obvykle při záchvatových onemocněních, ztrátě vědomí, po mozkové příhodě a při poruchách spánku. Používá se i při sledování procesů probíhajících ve spánku nebo při sledování reakcí na určité podněty (ERP).

EEG signál není stacionární, to znamená, že jeho frekvenční i amplitudové vlastnosti se s časem mění. V signálu se mohou vyskytnout artefakty, případně nestacionarity (epileptické grafoelementy apod.). Jeho segmentací na menší úseky se získá signál po částech stacionární, což je nutnou podmínku pro další zpracování (určení frekvenčního odhadu, apod.).



Obr. 1: Ukázka křivek v EEG záznamu

Vztah EEG/ERP

Událostí evokovaný potenciál (ERP) je každá stereotypní elektrofyziologická odpověď na vnitřní nebo externí podněty. Jednodušeji řečeno je to každá měřená mozková odpověď, která je přímo výsledkem myšlení nebo vnímání. Experimentální psychologové a neurologové objevili mnoho různých stimulů, které spolehlivě vyvolávají ERP u měřených subjektů. Načasování těchto odezev je považováno za čas potřebný k průběhu komunikace uvnitř mozku nebo za čas potřebný ke zpracování informací. Např. P300 odpověď nastává přibližně okolo 300ms bez ohledu na typ podnětů (vizuální, taktilní, sluchový, čichový, chuťový, atd.).

Zpracování ERP a Fourierova transformace

Chceme-li získat informace nečitelné ze signálu v nezpracovaném stavu, je třeba signál upravit. Nejpoužívanější metodou úpravy signálu je aplikace matematické transformace. Signály lze podle změny frekvenčního složení v čase rozdělit na *signály stacionární* (konstantní frekvence) a *nestacionární* (frekvence a amplituda se v čase mění). Jak už bylo výše zmíněno, EEG patří do množiny nestacionárních signálů. Při analýze stacionárních signálů nám stačí znát pouze frekvence obsažené v signálu. U signálů, u nichž se frekvenční složky s časem mění, nás zajímá nejenom frekvenční obsah, ale také délka trvání konkrétní složky (čas). Jedná se většinou o přechodné jevy nebo průběhy zahrnující různé náhlé zlomy, změny frekvencí nebo amplitudové skoky (např. ERP). Standardně, zaznamenáváme-li signál, zaznamenáváme ho jako funkci času. Jinými slovy zjišťujeme jak se mění měřená veličina (amplituda) v čase. Často nás zajímá informace skrytá ve frekvenčním obsahu signálu. *Fourierovy transformace* (FT) se spíše používá u stacionárních signálů, protože u nestacionárních signálů aplikací FT ztrácíme časovou informaci. Proto se nám FT nehodí k detekci ERP, jelikož potřebujeme vědět jak se frekvence a amplituda signálu s časem mění, abychom mohli na konkrétním místě zjistit výskyt ERP.

Výhody waveletové transformace

Waveletová transformace (WT) patří do třídy MRA (Multi Resolution Analysis) nástrojů pro zpracování zejména nestacionárních signálů. Waveletová transformace poskytuje oproti FT informaci o časové lokalizaci spektrálních složek. FT využívá kosinové a sinové funkce pro rozklad signálů, a používá se pro popis periodických signálů. WT nabízí nový přístup k analýze signálů použitím speciálního filtru nazvaného wavelet (vlnka). Každá waveletová funkce osciluje pouze v okolí bodu lokalizace, což poskytuje dobrou prostorovou lokalizaci. Cílem WT je rozložit vstupní signál do řady waveletových koeficientů. Toho se dosáhne filtrováním signálu párem ortogonálních filtrů. Ty se často označují jako otcovský wavelet a mateřský wavelet. Otcovský wavelet určuje celkový trend signálu - rozklad na škálové koeficienty, zatímco mateřský wavelet zachycuje doplňkovou informaci o „jemnostech“ na jednotlivých úrovních - waveletové koeficienty. U waveletových koeficientů na jednotlivých úrovních rozkladu platí, že mají velkou hodnotu, podle toho jak se daný wavelet v daném tvaru a roztažení podobá průběhu signálu v daném okamžiku. Základní rozdíl mezi FT a WT je v tom, že wavelety nejsou periodické funkce. Wavelet můžeme roztahovat a posouvat po zkoumaném signálu, tím lokalizujeme frekvence signálu v čase. Díky tomu je WT považována za velmi výhodnou pro analýzu nestacionárních nebo aperiodických signálů. WT se běžně používá v různých oborech jako je komprese obrazu, analýza řeči, analýza přechodných dějů, odhalování poruch, odstranění šumu signálu, atd.

3 Algoritmy waveletové transformace

Algoritmů pro waveletovou transformaci existuje několik druhů. Od spojité waveletové transformace (CWT) až po různé kombinace diskretních waveletových transformací (DWT).

Waveletová transformace je okenní operace. Jádru waveletové transformace je získáno posunutím a roztažením vybrané báze funkce. Wavelety jsou speciální okenní funkce $\psi(t)$, které mají nulovou střední hodnotu.

Diskretní waveletová transformace

Často se objevuje požadavek, aby studovaný signál byl plně rekonstruovatelný z nějaké vhodné diskretní sítě (vhodné je $N = 2^n$, n je z množiny \mathbb{Z}). Příslušný diskretní systém waveletů musí, z důvodu rekonstruovatelnosti, tvořit ortonormální bázi v $L^2(\mathbb{R})$. Jedná se o výpočet škálových a waveletových koeficientů. Škálové koeficienty určují celkový trend vstupního signálu a waveletové koeficienty obsahují doplňkovou informaci. Při volbě vhodného waveletu by se mělo přihlídnout k tomu, že by měl sledovat průběh zpracovávaného signálu. V důsledku ortogonality budou koeficienty pro výpočet doplňkové informace při daných filtračních koeficientech:

$$q_{L-1-n} = (-1)^n h_n \quad \sum_{\forall n} q_n = 0$$

Pyramidální algoritmus

Algoritmus výpočtu se realizuje jako postupný přechod z vyšší hladiny $j-1$ na nižší j . V první hladině multirozkladu $j = 1$ transformujeme signál do dvou částí, a to hrubší aproximace a detailní složky, jejíž koeficienty představují nízkofrekvenční a vysokofrekvenční informaci o signálu. V dalším kroku multirozkladu provádíme stejnou transformaci na aproximaci signálu získanou v předchozí fázi. Detailní složky na daných hladinách již nerozkládáme. Výpočet je proveden na konečném počtu hladin $j = 1, 2, 3, \dots, J$ se vstupní sekvencí na úrovni $j = 0$.

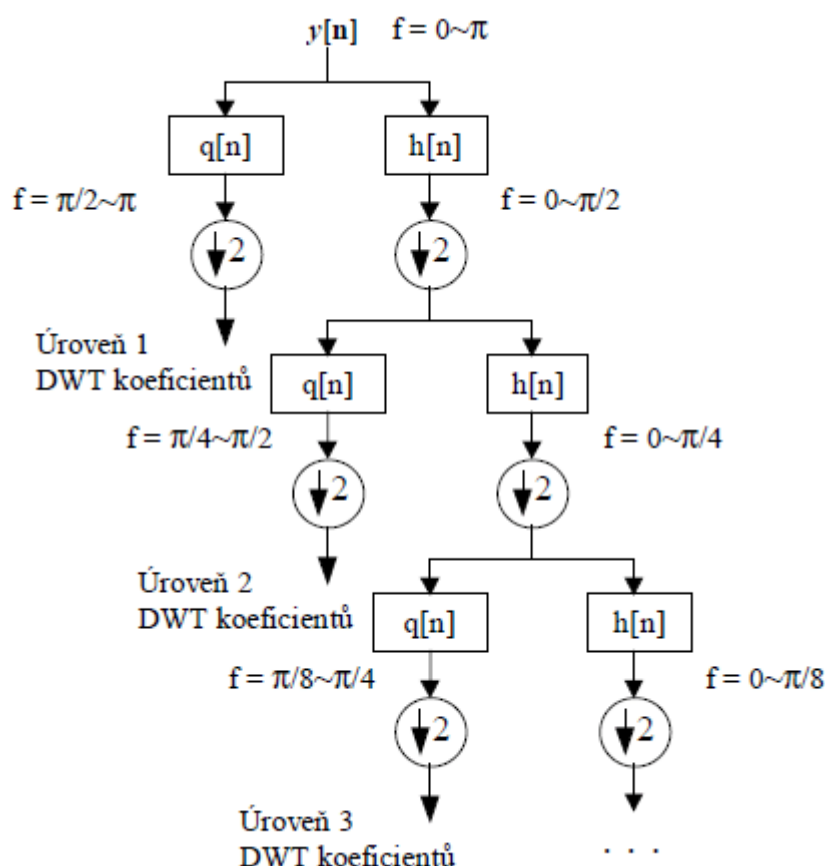
Jedná se o rozklad signálu na škálové koeficienty:

$$y_k^{(j)} = \sum_n y_n^{(j-1)} h_{n-2k}, \quad n = 0, 1, \dots, N-1, \quad k = 0, 1, \dots, \frac{N}{2}-1$$

a waveletové koeficienty:

$$d_k^{(j)} = \sum_n y_n^{(j-1)} q_{n-2k}, \quad n = 0, 1, \dots, N-1, \quad k = 0, 1, \dots, \frac{N}{2} - 1$$

Mějme vstupní signál y s šířkou pásma π . Tento signál je nejprve filtrován dolnoproputným filtrem h a hornoproputným filtrem q . Tyto signály jsou poté podvzorkovány dvěma, protože zabírají jen polovinu původního pásma.



DWT rozkládá vstupní signál do malého počtu „velkých“ dat uložených v koeficientech $y_k^{(j)}$ a velkého počtu „malých“ dat, kterými jsou koeficienty $d_k^{(j)}$, $j = 1, 2, \dots, J$. Tak se otevírá prostor pro různé formy jejich zpracování, jako jsou například komprese, vyhlazování a filtrace.

Paketový rozklad

Paketový rozklad nám umožňuje dále analyzovat i detailní složky a zpřesňovat tak frekvenční lokalizaci výsledných koeficientů. Ve svém důsledku je možné rozkládat libovolnou složku (aproximaci, detail) na libovolné hladině.

4 Filtrace šumu ze signálu

Potlačování rušivých složek signálů představuje jednu z významných aplikací DWT a skládá se ze tří po sobě následujících kroků:

- **dekompozice** signálu do určité úrovně P ;
- **prahování** výsledných DWT koeficientů;
- **rekonstrukce** signálu s použitím upravených detailních koeficientů od úrovně 1 až P a aproximačních koeficientů z úrovně P ;


Prahoování koeficientů je přitom možné realizovat volbou globální úrovně společné pro všechny úrovně rozkladu (global thresholding) nebo je možné tuto úroveň odlišit pro dílčí dekompoziční úrovně a aplikovat prahování lokální (level-dependent thresholding). Při aplikaci prahování lze volit prahování měkké (soft) a tvrdé (hard) nebo volit vlastní prahovací algoritmy. Při tvrdém prahování se vynulují koeficienty jejichž absolutní hodnota je menší než δ podle vztahu:

$$y_{\text{hard}}(n) = \begin{cases} x(n) & \text{pro } |x(n)| > \delta \\ 0 & \text{pro } |x(n)| \leq \delta \end{cases}$$

Měkké prahování probíhá stejným způsobem, ale navíc se hodnota δ odečítá od absolutních hodnot koeficientů větších než δ podle vztahu:

$$y_{\text{soft}}(n) = \begin{cases} \text{sign}(x(n)) (|x(n)| - \delta) & \text{pro } |x(n)| > \delta \\ 0 & \text{pro } |x(n)| \leq \delta \end{cases}$$

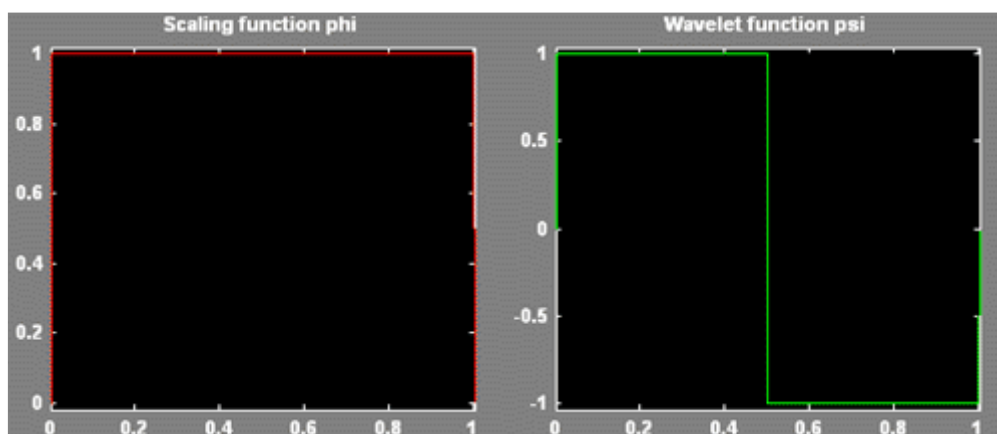
V porovnání s tvrdým prahováním nezpůsobuje měkké prahování nespojitosti ve výsledném zrekonstruovaném signálu. V programu Matlab se měkké prahování používá implicitně k odstraňování rušivých složek a tvrdé prahování ke kompresi. Na obr. 2 je zobrazen původní signál před filtrací a po filtraci při nulování rušivých složek do úrovně 4. K waveletové transformaci byl použit wavelet Daubechies8.



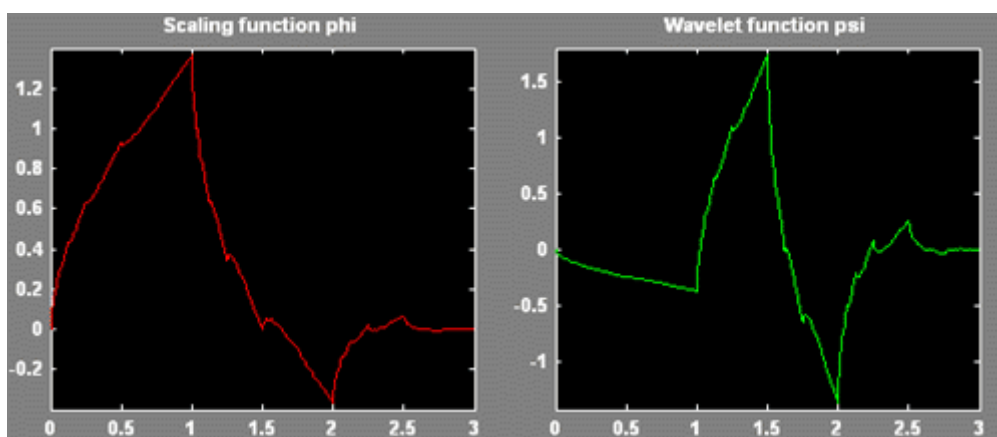
Obr. 2: Filtrace signálu, signál před filtrací (nahore) a po filtraci (dole)

5 Výsledky detekce ERP (P300)


Při zpracování EEG signálu a následnému hledání evokovaného potenciálu jsem použil 5 typů mateřského waveletu (Haar, Daubechies2, Daubechies4, Daubechies8, Symmlet4). Čísla v uvedených waveletech neudávají počet koeficientů daného waveletu, ale řád. Názvy těchto waveletů jsem převzal z programu Matlab, jelikož se v různých publikacích názvy často rozcházejí a jeden z požadavků byl, aby se výsledky mnou implementované WT shodovaly s výsledky v tomto programu.




Obr. 3: Haar škálová a weveletová funkce



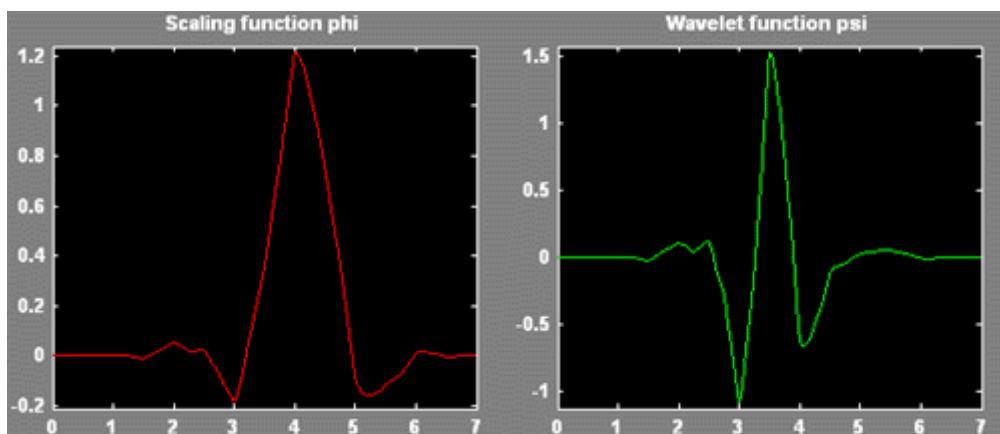
Obr. 4: Daubechies2 škálová a weveletová funkce



Obr. 5: Daubechies4 škálová a weveletová funkce



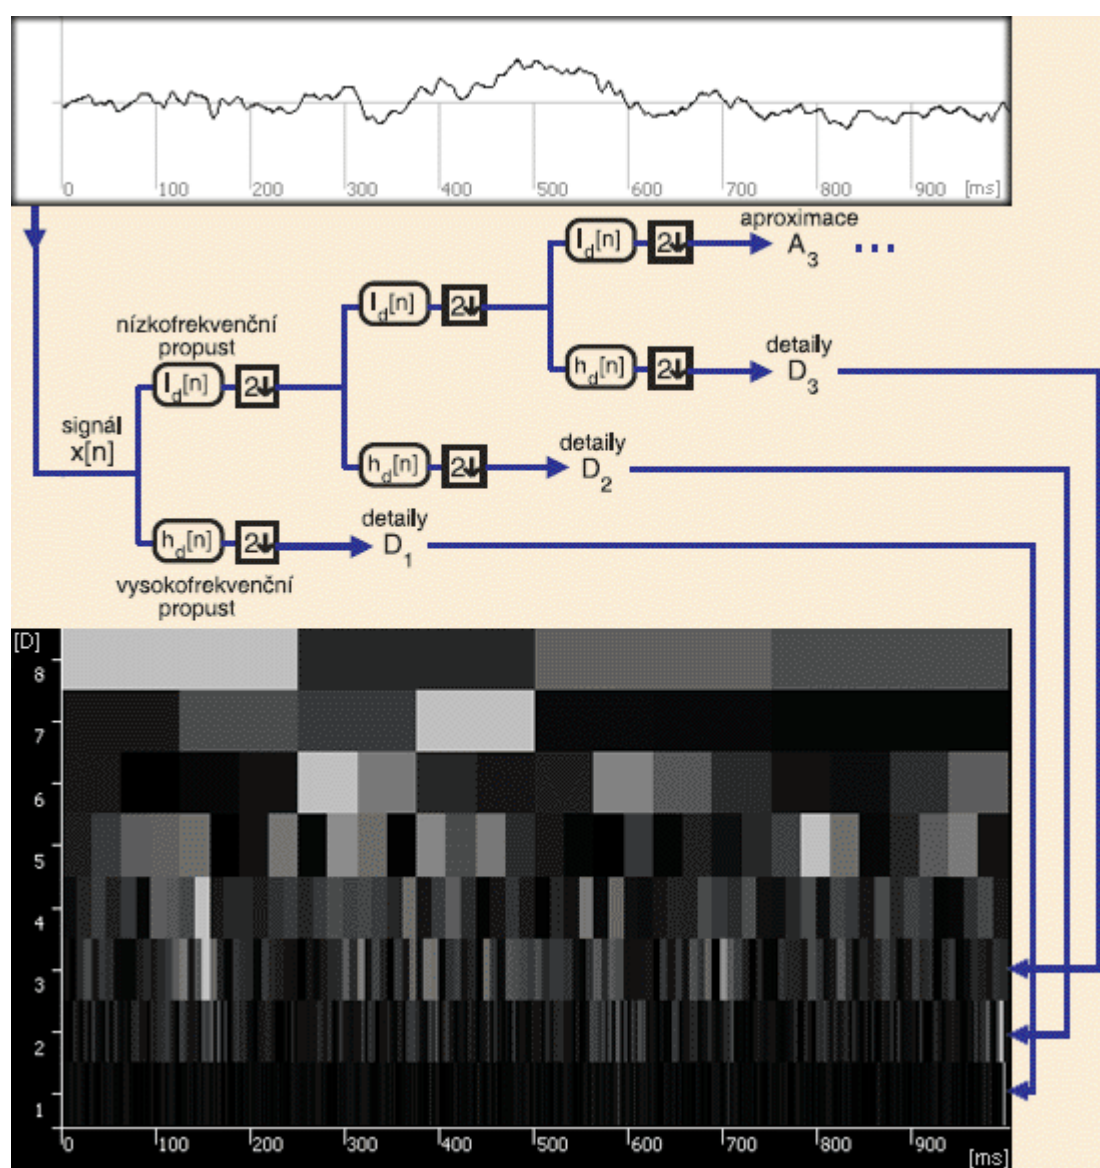
Obr. 6 : Daubechies8 škálová a weveletová funkce



Obr. 7 : Symmlet4 škálová a weveletová funkce

Rozklad na aproximační a detailní koeficienty

Rozklad signálu při waveletové transformaci začíná s originální frekvencí a v každém kroku se zmenšuje počet hodnot signálu na polovinu a stejným způsobem se snižuje také frekvence. To znamená, že v každém kroku se dvojnásobně zvětšuje délka mateřského waveletu. Transformace se zastavuje ve chvíli, kdy je délka signálu menší nežli délka signálu, tím se dosahuje maximálního rozkladu. Získané detailní koeficienty se zobrazují do tzv. scalogramu, který je reprezentovaný 64 barvami. Ve scalogramu jsou tedy zobrazeny hodnoty koeficientů ve všech úrovních rozkladu v závislosti na posunu mateřského waveletu. Nejsvětější barva zobrazuje, že se v daném měřítku (úrovni rozkladu) wavelet nejvíce shoduje s průběhem signálu a nejtmavší barva naopak znázorňuje nejmenší shodu.




Obr. 8: Rozklad signálu waveletem Daubechies4 na waveletové koeficienty znázorněné do scalogramu

Výsledky detekce ERP (P300)

Průběhy evokovaných potenciálů jsou již dávno vypořádovány a proto můžeme tyto informace využít k jejich automatické detekci. Evokovaný potenciál P300, jinak označovaný jako P3 se vyskytuje v signálu přibližně 300 ms po určitém stimulu, který by měl P3 vyvolat a trvá přibližně 200 ms – 300 ms. Automatické vyhledávání evokovaných potenciálů v obecných EEG signálech libovolné délky je nemožné, jelikož nemůžeme vědět, zda jde opravdu o evokovaný potenciál a ne o libovolnou anomálii, která se v EEG záznamu vyskytnout může. Tato detekce by ve výsledku neměla žádný smysl, jelikož bychom ani nevěděli na jakou událost měřený subjekt reagoval. ERP experimenty jsou většinou postaveny tak, že se uchováva kromě EEG záznamu také informace o časovém výskytu určitého stimulu, proto víme, kde bychom měli evokovaný potenciál očekávat.

Klasifikátor, který klasifikuje zda se v daném signálu vyskytuje hledaný evokovaný potenciál, vyhledává ve výstupních signálech waveletové transformace koeficienty nejvyšší shody waveletu s průběhem signálu. Samozřejmě aby wavelet popisoval evokovaný potenciál, musí mít také jeho délku. Jelikož implementovaná transformace pracuje na dvojkové mřížce, hledá se v úrovni rozkladu, kde je wavelet roztažen na délku 256 ms. Pokud se koeficienty nejvyšší shody vyskytují v rozmezí od 256 – 384 ms je detekce pozitivní v opačném případě negativní. Zkoumané signály (epochy – označený segment signálu po výskytu stimulu) mají délku 700 ms, jelikož víme, že přibližně v takovém úseku by se měl evokovaný potenciál P300 objevit. Tímto způsobem by se mohly detekovat i jiné typy evokovaných potenciálů. Stačilo by pouze použít správný wavelet a změnit hodnoty délky a výskytu.



Obr. 9: Ukázka vlny P300

Výsledky při použití jednotlivých typů waveletů:

Typ waveletu	Počet epoch	Správně klasifikovaných		Chybná pozitivní detekce	Chybná negativní detekce
		Počet	%		
Haar	20	18	90,0	1	1
Daubechies2	20	12	60,0	4	4
Daubechies4	20	12	60,0	2	6
Daubechies8	20	11	55,0	1	8
Symmlet4	20	14	70,0	1	5

6 Závěr

Z výsledků je vidět, které typy waveletů se k řešení dané problematiky hodí nejvíce. Zajímavé jsou rozlišné výsledky waveletů Daubechies4 a Symmlet4, protože když se podíváte na obrázky průběhů těchto waveletů uvedených výše, jistě si všimnete, že jsou téměř identické. Nejlepší výsledky detekce P300 má Haarův wavelet a na druhém místě je Symmlet4, i když Daubechies4 a Symmlet4 jsou vlně P300 nejvíce podobné. Takovéto výsledky mohou být způsobené posunem po dvojkové mřížce. Pokud bychom použili spojitou waveletovu transformaci s krokem 1 bez podvzorkování, jistě bychom dostali podrobnější výsledky, samozřejmě bychom za to zaplatili pomalejším výpočtem a větší částí výpočetní paměti.

Pro ukázkou jsem v práci také uvedl odstranění šumu z naměřeného signálu, jelikož je to jedna z velice významných úloh diskrétní waveletové transformace a funguje zcela spolehlivě, jak je vidět na obrázku č. 2.

Celá práce byla vytvořena v programovacím jazyce Java 1.6.0_07.

Literatura

- [1] <http://measure.feld.cvut.cz/usr/staff/smid/wavelets/wavelet-intro-html.html>
- [2] <http://cs.wikipedia.org/wiki/DWT>
- [3] PROCHÁZKA Aleš a HOŠTÁLKOVÁ Eva - Zpracování biomedicínských signálů a obrazů. Článek časopisu Automatizace č. 6, 2007.
- [4] SOUKAL, Petr. Software pro zpracování ERP – segmentace signálu a označování artefaktů, Plzeň, 2008. Bakalářská práce na Katedře informatiky a výpočetní techniky Západočeské univerzity v Plzni. Vedoucí bakalářské práce Ing. Roman Mouček, PhD.